Structure de données Pandas : les Series (Séries)

1. Introduction

On peut décrire les séries de Pandas comme étant une colonne d'un dataframe, un tableau à une dimension (vecteur) ou encore une suite de valeurs, numériques ou non. On peut aussi décrire une série comme un ensemble de valeurs représentant une variable pour un ensemble d'observations ou d'individus. Une série a un nom : par exemple dans l'image ci-dessous, le nom de la série est "Variable". Tout comme les autres structures Python que nous avons déjà vues, une série possède aussi des index.

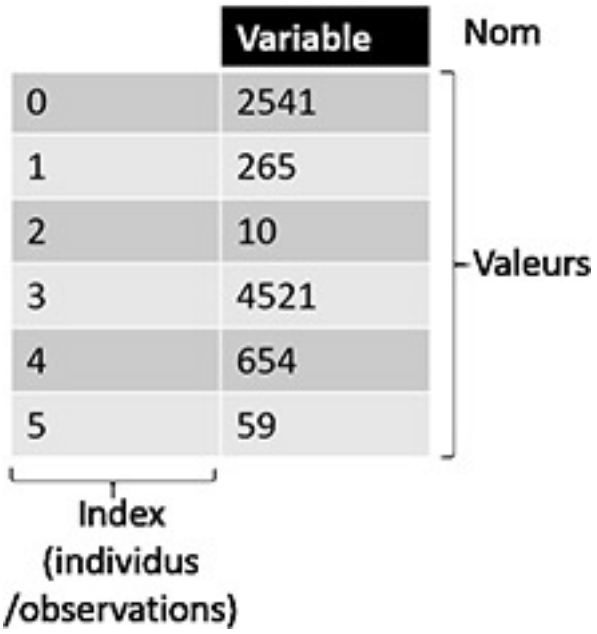

Une série peut être créée à partir d'une liste, d'un tableau NumPy, ou encore d'un dictionnaire, grâce à la méthode `Series()`. Elle peut aussi être créée à partir d'un fichier grâce aux fonctions de lecture de fichiers que nous avons vues précédemment, telles que `read_table()` ou `read_csv()`.

La structure de données `Series` possède deux composants principaux :

- les valeurs, auxquelles on peut accéder avec la méthode `values()`,

- les étiquettes, plus couramment appelées les index, auxquelles on peut accéder avec la méthode `index()`.

La série possède un seul axe, il s'agit de l'axe des index, contrairement au dataframe, que nous verrons plus tard, qui contient deux axes : les lignes et les colonnes.

Il faut savoir que pour les séries, par défaut, les index sont des nombres entiers : ils commencent à 0 et s'incrémentent, comme les `ndarrays` de NumPy. Mais il est aussi possible de remplacer ces index entiers par des étiquettes du type que l'on souhaite (nombres, caractères). Par exemple, si on préfère mettre des lettres comme index plutôt que des nombres, Pandas nous autorise à le faire. Ainsi, on pourra accéder aux valeurs de la série soit en donnant la position de la valeur entre crochets, soit en donnant l'étiquette correspondant à cette valeur, toujours entre crochets.

Enfin, au sein d'une série, il est fortement conseillé d'utiliser des données qui sont homogènes, de même type (uniquement des valeurs numériques, uniquement des valeurs de type caractères, etc.), même si le stockage de valeurs de types hétérogènes est permis.

2. Créer des séries

Pour pouvoir créer sa première série, il faut d'abord importer la librairie Pandas, puis utiliser la fonction `Series()`.

Voici la syntaxe générale :

```
import pandas as pd
serie=pd.Series(donnees)
```

On peut créer et remplir cette série de différentes manières.

a. À partir de valeurs aléatoires

Tout d'abord, il est possible de créer une série à partir de valeurs aléatoires, déterminées grâce à `choice()` du module `random` de NumPy : `random.choice()` (choix

aléatoire).

La syntaxe d'utilisation de la fonction `random.choice()` est la suivante :

```
import numpy as np
np.random.choice(data, size)
```

On importe la librairie NumPy et on crée un alias `np` afin de simplifier l'écriture de NumPy et donc l'appel de ses fonctions. Puis on appelle la fonction `random.choice()` contenue dans la librairie NumPy. Cette fonction prend en premier argument une structure contenant des données, par exemple une liste `(data)`. Puis on spécifie le nombre de valeurs qu'on veut piocher aléatoirement dans cet objet `data` avec l'argument `size` (taille). Enfin, il suffit de donner la sortie de cette fonction à la fonction `Series()` de Pandas pour créer une série contenant ces valeurs aléatoires.

Syntaxe de création de la série

```
import numpy as np
import pandas as pd
pd.Series(np.random.choice(data, size))
```

Passons à l'exemple pratique, avec le code ci-dessous :

```
import numpy as np
import pandas as pd
mes_nombres = pd.Series(np.random.choice(list(range(0,500)),10))
print(mes_nombres)
```

Ici, on importe les librairies NumPy et Pandas. Ensuite, on crée une liste contenant 500 valeurs, de 0 à 499 : il s'agit de l'objet `data` dans la syntaxe d'exemple. Enfin, on sélectionne dix valeurs aléatoirement dans cette liste grâce à la fonction `random.choice()`. En utilisant la fonction `Series()` de Pandas, on obtient un objet de classe `Series`, contenant dix valeurs aléatoires comprises entre 0 et 499, rangées dans la variable `mes_nombres`. Pour la visualiser, il suffit d'utiliser la fonction `print()` de Python.

Résultat

```
0   213
1   259
2   478
3   351
4   361
5   251
6    82
7    21
8   124
9   234
dtype: int32
```

Si vous lancez ce code dans votre propre notebook, sachez qu'il est normal que vous n'obteniez pas les mêmes valeurs dans votre série. En effet, ce sont des valeurs aléatoires.

Dans le résultat du code, nous pouvons voir qu'il y a deux "colonnes", ce sont les deux composants principaux des séries dont nous parlions précédemment : à gauche se trouvent les index et à droite les valeurs. Dans cet exemple, les index vont de 0 à 9, puisque par défaut, ceux-ci commencent à 0 puis s'incrémentent autant de fois qu'il y a de valeurs. En bas de la série, on peut apercevoir une information supplémentaire, le `dtype`, qui représente le type de données stockées dans la série ; ici, le type est `int32` (nombres entiers).

b. À partir d'une liste Python

À partir d'une liste Python, la syntaxe pour créer une série est la suivante :

```
pd.Series(liste)
```

Voici un code exemple

```
import pandas as pd
ma_serie = pd.Series([25,45,62,12,11])
print(ma_serie)
```

Avec ce code, nous venons de créer une série grâce à une liste Python, contenant une suite de valeurs numériques. Cette liste a été créée grâce aux crochets `[]`. La fonction `Series()` de Pandas prend en entrée cette liste Python, qui contient une suite de nombres, et crée un objet de type `Series` qui est stocké dans la variable `ma_serie`.

Résultat

```
0   25
1   45
2   62
3   12
4   11
dtype: int64
```

Pour la première création de série, Python avait choisi `int32` comme type de données, puis lors de la création de la deuxième série, il a choisi `int64`. C'est un choix qu'il juge être le plus judicieux selon la manière dont nous créons les séries numériques. La différence entre `int32` et `int64` est leur capacité de stockage. Par exemple, `int32` permet de stocker des valeurs comprises entre -2 147 483 648 et +2 147 483 647 et `int64` peut stocker des valeurs comprises entre -9 223 372 036 854 775 808 et +9 223 372 036 854 775 807.

Attention toutefois lorsque vous créez des séries à partir de listes, car celles-ci acceptent des données hétérogènes, ce qui n'est pas conseillé dans le cas des séries. Voyons ensemble comment réagit Python lorsqu'on essaye de créer une série à partir d'une liste

contenant des valeurs de types hétérogènes.

Code

```
ma_liste = ["hello", 1,2,3]
print(ma_liste)
```

Résultat

```
['hello', 1, 2, 3]
```

Ici, nous créons une liste contenant la chaîne de caractères `hello` ainsi que des chiffres. On voit que la liste contient bien une valeur de type caractère et trois valeurs entières, puisqu'elle accepte les données de types hétérogènes.

Les séries, elles, peuvent accepter des données hétérogènes, mais cela n'est pas conseillé en matière de performance. Ainsi, si on crée une série à partir de cette liste, cela donne :

Code

```
import pandas as pd
print(pd.Series(ma_liste))
```

Résultat

```
0    hello
1        1
2        2
3        3
dtype: object
```

Le `dtype` ici est `object` : ce `dtype` correspond soit au type `str` de Python, pour *string* (chaîne de caractères), soit à des types mixtes (c'est-à-dire un mélange de chaînes de caractères, nombres, etc.). Ainsi, ici, on a des données hétérogènes dans la série créée, les séries les gèrent.

Pour voir les différents types que la série contient, on peut utiliser la fonction `type()` de Python.

Code

```
series_mixed=pd.Series(ma_liste)
print(type(series_mixed[0]))
print(type(series_mixed[1]))
```

Résultat

```
<class 'str'>
<class 'int'>
```

On constate que `Hello`, la valeur à l'index 0 de l'objet `series_mixed`, est bien considérée comme une valeur de type `str` et que la valeur `1` est bien considérée comme une valeur de type `int` par Python.

Toutefois, il n'est pas conseillé d'utiliser des données hétérogènes dans les séries et il n'y a pas d'intérêt à avoir de données mixtes dans une variable (une colonne).

Avec Pandas, les différents types sont les suivants :

`object` = chaines de caractères, texte (`str` en Python)

`int64/int32` = valeurs entières numériques (`int` en Python)

`float64` = valeurs réelles, à virgules (`float` en Python)

`bool` = booléens, valeurs VRAIE ou FAUX (`bool` en Python)

c. À partir d'un tableau NumPy (ndarray)

Il est aussi possible de créer une série à partir d'un tableau NumPy (`ndarray`).

Syntaxe

```
import pandas as pd
series = pd.Series(numpy_array)
```

Cela ne change pas beaucoup de la création de la série à partir d'une liste Python.

d. À partir d'un fichier texte

Si vous avez lu la section de ce chapitre sur la lecture et l'écriture de fichiers avec Pandas, ces commandes ne vous seront pas inconnues. Nous allons ici lire une colonne spécifique de notre jeu de données sur les Jeux olympiques, qui nous servira d'exemple pour illustrer nos propos sur les séries.

Pour rappel, l'option `squeeze` permet de dire à Pandas que l'on souhaite créer un objet de classe `Series`, lors de la lecture du fichier, et non pas un dataframe.

Nous allons sélectionner la colonne `Weight` de notre tableau, qui correspond au poids des athlètes.

Code

```
import pandas as pd
ma_serie_de_poids_index_defaut=pd.read_csv("../datasets/120-
years-of-olympic-history-athletes-and-results.csv", usecols=[5],
squeeze=True)
print(ma_serie_de_poids_index_defaut)
```

Résultat

```
0      80.0
1      60.0
2       NaN
3       NaN
4      82.0
      ...
```

```
271111    89.0
271112    59.0
271113    59.0
271114    96.0
271115    96.0
Name: Weight, Length: 271116, dtype: float64
```

Nous venons de créer une série, dont les index vont de 0 à 271 115. Le nom de cette série (`Name`) est `Weight`. La taille de la série, c'est-à-dire le nombre de valeurs qu'elle contient, est de 271 116. Enfin, le type des données (`dtype`) de cette série est `float64`, c'est-à-dire qu'il s'agit de nombres réels. Certaines valeurs sont égales à `NaN`, ce sont les valeurs manquantes en Python et cela signifie qu'en créant ce jeu de données sur les athlètes des JO, le poids de certains d'entre eux n'a pas pu être renseigné. Nous verrons plus en détail les valeurs manquantes au cours de ce chapitre.

3. Choisir l'index d'une série

Lorsque nous avons créé notre série, appelée `ma_serie_de_poids_index_ defaut` , dans la section précédente, nous avons laissé les index par défaut. Ceux-ci commencent à 0 et s'incrémentent. Avec Pandas, il est possible de définir ses propres index, par exemple lors de la lecture d'un fichier.

Syntaxe pour définir soi-même les index

```
serie = pd.read_csv("mon_fichier.csv", index_col=[colonne1]
squeeze=True, usecols=[colonne1,colonne2])
```

Avec cette syntaxe, on définit quelle colonne du fichier utiliser pour créer la série. Précédemment, on sélectionnait une seule colonne, qui permettait de définir les valeurs de la série. Ici, le principe est de sélectionner deux colonnes avec l'option `usecols`, puis de définir l'une d'elles comme étant l'index de la série avec l'option `index_col`.

Illustrons cela avec un exemple. Nous allons créer une série avec la colonne `Weight` du fichier des Jeux olympiques comme valeurs et la colonne

`Name` du fichier comme index.

Code

```
import pandas as pd
ma_serie_de_poids=pd.read_csv("../datasets/120-years-of-olympic-
history-athletes-and-results.csv", usecols=[1,5], squeeze=True,
index_col=[0])
ma_serie_de_poids
```

Dans ce code, on lit le fichier, on demande à Pandas de sélectionner les colonnes `1` et `5`, respectivement `Name` et `Weight`, avec l'option `usecols`. On spécifie aussi à Pandas qu'on souhaite que l'objet créé soit de classe `Series`, grâce à l'option `squeeze`, et on lui définit que la première colonne de cet objet (la colonne `Name` ici) correspondra aux index, avec l'option `index_col`.

Résultat

```
Name
A Dijiang              80.0
A Lamusi               60.0
Gunnar Nielsen Aaby     NaN
Edgar Lindenau Aabye    NaN
Christine Jacoba Aaftink  82.0
                       ...
Andrzej ya             89.0
Piotr ya               59.0
Piotr ya               59.0
Tomasz Ireneusz ya     96.0
Tomasz Ireneusz ya     96.0
Name: Weight, Length: 271116, dtype: float64
```

On constate qu'à présent, les index correspondent aux noms des athlètes. Lorsqu'on souhaite accéder à certaines valeurs d'une série, il est parfois plus pratique de le faire avec des noms d'index qui correspondent à quelque chose (par exemple des noms d'athlètes) qu'avec des chiffres incrémentés. C'est dans ce cas précis qu'on voit la puissance des séries, avec la possibilité d'ajouter l'étiquette souhaitée à nos valeurs.

4. Accéder aux valeurs d'une série

a. Indexing via la position des valeurs

Lorsqu'on souhaite sélectionner une ou des valeurs dans une série, on va chercher à sélectionner des données à des positions particulières. Dans la documentation anglaise, vous verrez sûrement le terme *indexing*. Avec Pandas, et Python en général, *indexing* pourrait être traduit par "vouloir accéder à un sous-ensemble de données de notre structure, dans notre cas, de notre série". Nous avons déjà vu ce principe d'indexing ensemble avec les listes ou encore les `ndarrays` de NumPy.

Le premier type d'indexing est l'indexing via la position des valeurs dans la série.

Par exemple, si on souhaite récupérer la valeur en position 2 dans l'objet `ma_serie`, la syntaxe est :

```
ma_serie[1]
```

En se rappelant toujours que les positions en Python commencent à 0, donc 1 correspond à la valeur en position 2.

Pour sélectionner plusieurs valeurs, il suffit de donner une liste de positions, d'index, entre crochets, avec la syntaxe suivante :

```
ma_serie[[1,5,9]]
```

Ici, le premier couple de crochets `[1,5,9]` permet de créer la liste de valeurs et le deuxième couple de crochets `[ ]` permet d'effectuer l'indexing sur l'objet `ma_serie`.

Il est aussi possible d'utiliser des valeurs négatives. Par exemple, `-1` signifie "la dernière valeur de la série", `-2` signifie "l'avant-dernière valeur de la série", etc.

Syntaxe

```
ma_serie[-1]
```

Passons à l'exemple pratique. Pour récupérer plusieurs valeurs à plusieurs positions, il suffit de donner une liste de ces positions entre crochets. Récupérons les valeurs de poids des athlètes aux positions 0, 15, 6985 et 452.

Code

```
ma_serie_de_poids_index_defaut[[0,15,6985,452]]
```

Le premier couple de crochets `ma_serie_de_poids[]` correspond à la syntaxe pour sélectionner des données et le deuxième couple de crochets `[0,15,6985,452]` correspond à la liste des positions auxquelles on souhaite récupérer des valeurs.

Résultat

```
0      80.0
15     75.0
6985   59.0
452    56.0
Name: Weight, dtype: float64
```

Nous venons de récupérer les valeurs aux positions 0, 15, 6985 et 452.

b. Indexing via l'étiquette des valeurs

Il est aussi possible de sélectionner des valeurs selon l'étiquette de ces valeurs. Par exemple, imaginons que nous voulons sélectionner la valeur dont l'étiquette est la chaîne de caractères "`ma_valeur`". La syntaxe sera la suivante :

```
ma_serie["ma_valeur"]
```

Pour sélectionner plusieurs valeurs :

```
ma_serie[["ma_valeur1", "ma_valeur2","ma_valeur3"]]
```

Pour l'exemple de cette sous-section, nous allons repartir sur la série que nous avons créée précédemment et sur laquelle nous avons redéfini les index avec les noms des athlètes : `ma_serie_de_poids`.

Dans notre cas, il suffit de donner les noms des athlètes qui nous intéressent dans une liste. Imaginons que nous voulons récupérer le poids d'Antti Sami Aalto et de Andrzej ya.

Code

```
ma_serie_de_poids[["Antti Sami Aalto","Andrzej ya"]]
```

Résultat

```
Name
Antti Sami Aalto    96.0
Andrzej ya          89.0
Name: Weight, dtype: float64
```

Ce code nous permet d'accéder à l'information de poids de ces deux athlètes qui font respectivement 96 et 89 kg.

L'indexing avec les positions des valeurs ou leurs étiquettes, entre crochets `[]`, est très répandu mais peut être à l'origine d'erreurs de mauvaise sélection de données. Pour que ces erreurs n'arrivent pas, les attributs `.loc` et `.iloc` ont été mis en place, nous allons voir cela ensemble.

c. Les indexeurs loc et iloc

Imaginons que les étiquettes d'index soient égales aux positions des valeurs, par exemple, que nous ayons une série de quatre valeurs dont les étiquettes d'index sont 1, 3, 2, 0 et dont les positions sont 0, 1, 2, 3. Cela va poser problème, car Pandas ne saura plus si nous lui demandons de récupérer la valeur selon l'étiquette de l'index, ou selon sa position dans la série.

Exemple pratique pour illustrer ce propos

Code

```
import pandas as pd
ma_serie=pd.Series([10,11,12,13], index=[1,3,2,0])
```

On crée une série nommée `ma_serie`, qui contient quatre valeurs et dont les noms d'index sont respectivement 1, 3, 2 et 0.

Résultat

```
1   10
3   11
2   12
0   13
dtype: int64
```

On constate que le nom de l'index à la position 0 est `1` et que le nom d'index à la position 4 de la série est `0`.

Imaginons que nous voulons récupérer la valeur `10`, soit la première valeur dans la série. Instinctivement, nous allons vouloir récupérer la valeur à la position 0 dans la série.

Code

```
ma_serie[0]
```

Résultat

```
13
```

Le résultat de ce code est la valeur `13` et non pas la valeur `10`, car Pandas récupère la valeur dont l'étiquette de l'index est 0. Cela peut générer des erreurs graves dans certaines analyses.

Heureusement, Pandas propose deux indexeurs pour spécifier à Python si nous souhaitons effectuer l'indexing sur les étiquettes d'index ou sur les positions des valeurs dans la série : ce sont les indexeurs `loc` et `iloc`. Ces indexeurs peuvent être considérés

comme des attributs des objets de classe `Series` et `DataFrame`.

Syntaxe

```
serie.loc[etiquette]
serie.iloc[position]
```

Les attributs sont suivis des étiquettes ou positions auxquelles on souhaite récupérer des valeurs, entre crochets `[]`.

L'attribut `loc` va demander à Pandas d'utiliser les noms d'index, les étiquettes, pour sélectionner les valeurs dans la série.

Code

```
ma_serie.loc[0]
```

Résultat

```
13
```

L'attribut `loc` retourne la valeur dont le nom de l'index est `0`.

L'attribut `iloc` va demander à Pandas d'utiliser la position des valeurs pour les sélectionner dans la série.

Code

```
ma_serie.iloc[0]
```

Résultat

```
10
```

L'attribut `iloc` retourne `10`, donc la valeur à la position `0` dans la série `ma_serie`.

d. Indexing via une expression booléenne

Enfin, il est possible de faire de l'indexing en utilisant une expression booléenne. Ici, cet indexing ne se base plus sur les positions ou les étiquettes des valeurs, mais réellement sur les valeurs de la série. Par exemple, si on veut récupérer l'ensemble des valeurs strictement supérieures à `10` dans la série, la syntaxe est la suivante :

```
ma_serie[ma_serie>10]
```

Ainsi, il s'agit d'utiliser les opérateurs de comparaisons (`<`, `<=`, `>`, `>=`, `==`, `!=`) pour effectuer l'indexing.

Cet indexing se fait en deux étapes, que nous allons découper et que nous illustrerons en une ligne de code. Voici la syntaxe générale de la première étape :

```
ma_serie > 10
```

Ici, on cherche à savoir quelles valeurs sont strictement supérieures à `10` dans l'objet `ma_serie`, grâce à une expression booléenne. Cela crée une nouvelle série de même taille que l'objet `ma_serie`, contenant des valeurs de type booléen (`bool`), c'est-à-dire une suite de valeurs `True` et `False`. Si la valeur à la position 0 de l'objet `ma_serie` est égale à 20, alors la valeur à la position 0 de la nouvelle série, contenant les booléens, est `True`. Si cette valeur est égale à 9, la valeur à la position 0 de la série contenant les booléens est `False`.

Ensuite, pour récupérer l'ensemble des valeurs strictement supérieures à 10, la syntaxe est la suivante :

```
ma_serie[ma_serie > 10]
```

Cela retournera une nouvelle série, contenant uniquement les valeurs de `ma_serie` supérieures à 10, c'est-à-dire uniquement les valeurs aux positions qui sont à `True` dans la série contenant les booléens.

Illustrons cela avec un exemple. Sélectionnons uniquement les athlètes avec un poids strictement supérieur à 90 kg.

Code

```
ma_serie_de_poids>90
```

Résultat

```
Name
A Dijiang              False
A Lamusi               False
Gunnar Nielsen Aaby    False
Edgar Lindenau Aabye   False
Christine Jacoba Aaftink  False
                       ...
Andrzej ya             False
Piotr ya               False
Piotr ya               False
Tomasz Ireneusz ya     True
Tomasz Ireneusz ya     True
Name: Weight, Length: 271116, dtype: bool
```

On constate une série de valeurs à `True` et `False`, de même taille que l'objet `ma_serie`, sachant que seuls les athlètes à `True` seront gardés dans le code ci-dessous.

Code

```
ma_serie_de_poids[ma_serie_de_poids>90]
```

Résultat

```
Name
Timo Antero Aaltonen    130.0
Andreea Aanei           125.0
```

```
Dagfinn Sverre Aarskog    98.0
Hans Aasns                93.0
Hans Aasns                93.0
                          ...
Henk Jan Zwolle           93.0
Dominik ycki              95.0
Dominik ycki              95.0
Tomasz Ireneusz ya        96.0
Tomasz Ireneusz ya        96.0
Name: Weight, Length: 16818, dtype: float64
```

Suite à cet indexing, on sait maintenant que 16 818 valeurs sont strictement supérieures à 90 dans cette série.

Si on souhaite effectuer plusieurs expressions booléennes, il faudra utiliser les opérateurs `&` (pour et), `|` (pour ou) et `~` (pour la négation). On les appelle les opérateurs *bitwise* (comparaison bit à bit) en Python.

Dans les chapitres précédents, et notamment dans le chapitre sur les rappels Python, nous avions utilisé les opérateurs logiques, `and`, `or` et `not`. Les opérateurs logiques fonctionnent bien sur des expressions qui renvoient une valeur `True` unique, ou une valeur `False` unique. Ici, les expressions booléennes retournent des séries de `True` et de `False`, pour chaque individu. Et dans ce cas, l'utilisation d'opérateurs logiques générera une erreur, alors que l'utilisation des opérateurs bitwise fonctionnera.

Par exemple, pour récupérer l'ensemble des valeurs strictement supérieures à 90 et strictement inférieures à 100, on peut utiliser l'opérateur `&`.

Code

```
ma_serie_de_poids[(ma_serie_de_poids>90) &
(ma_serie_de_poids<100)]
```

Résultat

```
Name
Dagfinn Sverre Aarskog    98.0
Hans Aasns                93.0
Hans Aasns                93.0
Hans Aasns                93.0
Hans Aasns                93.0
                          ...
Henk Jan Zwolle           93.0
Dominik ycki              95.0
Dominik ycki              95.0
Tomasz Ireneusz ya        96.0
Tomasz Ireneusz ya        96.0
Name: Weight, Length: 9891, dtype: float64
```

e. Slicing : découpage de valeurs successives

Tout comme pour les listes en Python, il est possible de faire du *slicing* (découpage) sur des séries, grâce aux symboles crochets `[]` et deux-points `:`.

Si vous n'êtes pas débutant en Python, vous avez déjà entendu parler des *slices*. Elles permettent de sélectionner des valeurs au sein de données, comme par exemple ici, les séries. Toutefois, contrairement aux listes, le slicing d'une série coupe/sélectionne les valeurs, mais aussi les index. La différence avec l'indexing est aussi que le slicing récupère des données consécutives, comprises dans un intervalle et n'utilise que des positions comme paramètres (on n'utilise pas les étiquettes, cela génère une erreur). Le but du slicing, tout comme l'indexing, est de récupérer un sous-ensemble de données qui nous intéressent.

Dans le cas où nous souhaitons sélectionner des valeurs au sein d'une série, la syntaxe générale est la suivante :

```
serie[start:stop:step]
```

Une autre possibilité pour le slicing qui est même conseillée est d'utiliser la méthode `iloc` plutôt que les crochets. Pour rappel, la méthode `iloc` permet de sélectionner des valeurs selon leur position. Précédemment, nous l'avons utilisée en lui précisant les positions à récupérer, mais sachez qu'il est aussi possible de lui donner des slices.

Syntaxe du slicing avec `iloc`

```
serie.iloc[start:stop:step]
```

Ici, on lui donne une slice en précisant la position de départ et la position de fin des valeurs, en sachant qu'il s'agit des valeurs jusqu'à la position `stop` non incluse. Vous verrez plus souvent le slicing effectué avec l'indexeur `iloc` qu'avec les crochets seuls, pour la librairie Pandas.

Que ce soit avec les crochets seuls ou avec l'indexeur `iloc`, il y a trois informations importantes entre crochets.

- `start` : permet de donner la position de départ de la sélection. Si on souhaite commencer la sélection à partir de la deuxième valeur de la série, on mettra le chiffre 1.
- `stop` : permet de donner la position de fin de la sélection, non incluse. Attention donc, car ce qu'attend Python est la position de fin souhaitée + 1. En fait, on pourrait voir le *slicing* comme une échelle, et lorsqu'on demande à Python de sélectionner des valeurs à certaines positions, il sélectionnera les valeurs aux positions à droite de la position `start` et strictement à gauche de la position `stop`. Pour que cela soit visuel, imaginons que l'on donne comme `start` la valeur 3 et comme `stop` la valeur 5 sur notre série contenant les valeurs de poids des athlètes, créée précédemment (`ma_serie_de_poids`). Cela donnerait ceci :

Les valeurs sélectionnées sont celles aux positions `3` et `4`. Il s'agit d'une gymnastique à retenir avec le slicing.

Exemple pratique

Pour bien comprendre le slicing, reprenons l'objet de type `Series` contenant le poids des athlètes, `ma_serie_de_poids_index_defaut` , pour pouvoir comprendre la sélection de valeurs avec le slicing.

Code

```
ma_serie_de_poids_index_defaut.iloc[3:5]
```

Résultat

```
3    NaN
4    82.0
Name: Weight, dtype: float64
```

Ici, on récupère bien les valeurs aux positions 3 et 4 de la série.

- Enfin, l'option `step` permet de spécifier le pas qu'on souhaite entre chaque valeur située entre le `start` et le `stop`. Imaginons que l'on donne comme `start` 2 et comme `stop` 11, avec un `step` de 2. La syntaxe générale serait la suivante :

```
Serie.iloc[2:11:2]
```

Les valeurs aux positions suivantes seront récupérées : 2, 4, 6, 8, 10. Alors que si nous ne donnions pas de valeur à `step`, avec la syntaxe générale suivante :

```
Serie.iloc[2:11]
```

les valeurs récupérées seraient : 2, 3, 4, 5, 6, 7, 8, 9, 10.

Exemple pratique

Appliquons ces lignes de code sur notre série exemple.

Code

```
ma_serie_de_poids_index_defaut.iloc[2:11:2]
```

Résultat

```
2     NaN
4    82.0
6    82.0
8    82.0
10   75.0
Name: Weight, dtype: float64
```

Code

```
ma_serie_de_poids_index_defaut.iloc[2:11]
```

Résultat

```
2     NaN
3     NaN
4    82.0
5    82.0
6    82.0
7    82.0
8    82.0
9    82.0
10   75.0
Name: Weight, dtype: float64
```

En plus des options `start`, `stop` et `step` qui permettent de faire du *slicing*, il existe quelques autres syntaxes de slicing intéressantes à utiliser, dont nous allons voir quelques exemples tout de suite.

- Il est possible de sélectionner des données d'une position `start` jusqu'à la fin de la série, avec la syntaxe suivante :

```
Serie.iloc[start:]
```

Ici, on ne donne pas de valeur après le `:`, Pandas en déduit qu'il doit sélectionner les valeurs jusqu'à la fin de la série.

- On peut aussi sélectionner des valeurs du début de la série jusqu'à une position `stop`, avec la syntaxe :

```
Serie.iloc[:stop]
```

- Enfin, il faut savoir que les valeurs `start` et `stop` peuvent être négatives, ce qui signifie que Pandas commence à compter par la fin de la série.

Par exemple, la syntaxe suivante :

```
Serie.iloc[-1:]
```

permet d'afficher la dernière valeur de la série. En effet, `-1` signifie la dernière valeur d'une liste, série ou autre ensemble de données séquentielles. En lui demandant d'aller de `-1` jusqu'à la fin de la série, grâce à la syntaxe `[-1:]`, Pandas n'affichera donc que la dernière valeur.

Pour afficher les deux dernières valeurs de la série, la syntaxe serait la suivante :

```
Series.iloc[-2:]
```

En effet, ici on demande d'aller de la deuxième valeur avant la fin, `-2`, jusqu'à la fin, puisqu'on ne spécifie pas de valeur `stop`.

Enfin, pour afficher toutes les valeurs de la série, sans les deux dernières, la syntaxe serait

la suivante :

```
Series.iloc[:-2]
```

En effet, on ne met pas de valeurs devant le `:`, ce qui signifie que le `start` part du début. Puis avec un `-2` comme option `stop`, Pandas s'arrêtera deux valeurs avant la fin.

Exemple pratique

Testons ces techniques de slicing sur notre série nommée `ma_serie_de_poids_index_defaut` .

Code

```
ma_serie_de_poids_index_defaut.iloc[1000:]
```

Résultat

```
1000     84.0
1001     84.0
1002     84.0
1003     73.0
1004     54.0
        ...
271111   89.0
271112   59.0
271113   59.0
271114   96.0
271115   96.0
Name: Weight, Length: 270116, dtype: float64
```

On constate que ce slicing génère un nouvelle série qui va de la position `1000` jusqu'à la fin de la série dont elle provient.

Pour afficher les vingt premières valeurs, le code est le suivant :

```
ma_serie_de_poids_index_defaut.iloc[:20]
```

Résultat

```
0    80.0
1    60.0
2     NaN
3     NaN
4    82.0
5    82.0
6    82.0
7    82.0
8    82.0
9    82.0
10   75.0
11   75.0
12   75.0
13   75.0
14   75.0
15   75.0
16   75.0
17   75.0
18   72.0
19   72.0
Name: Weight, dtype: float64
```

On obtient bien les vingt premières valeurs de notre série, des positions 0 à 19.

Enfin, affichons la dernière valeur de notre série, avec le code suivant :

```
ma_serie_de_poids_index_defaut.iloc[-1:]
```

Résultat

```
271115   96.0
Name: Weight, dtype: float64
```

Les possibilités du slicing sont très vastes, mais vous avez à présent de bonnes bases pour découper des séries selon vos besoins.

Il faut savoir que lorsqu'on découpe un objet Python à l'aide du slicing, le sous-objet créé est de même type que l'objet dont il provient. Par exemple, si on fait du slicing sur une série de type numérique, l'objet créé après le slicing sera une série de type numérique. De même que si nous effectuons un slicing sur une liste, l'objet créé sera une liste.

5. Les attributs et les méthodes des objets de classe Series

Les objets de classes `Series` possèdent des attributs et des méthodes qui sont très utiles lorsqu'on souhaite les analyser. L'ensemble des méthodes et des attributs existants n'est pas couvert, mais vous pouvez tous les retrouver dans la documentation Python sur les objets de classe `Series` : https://pandas.pydata.org/pandas-docs/stable/reference/api/pandas.Series.html

a. Les attributs des objets de classe Series

Pour rappel, en Python, chaque classe a ses propres attributs, qui sont des variables appartenant à cette classe et permettant d'obtenir rapidement des informations au sujet d'un objet de cette classe. Il existe donc un ensemble d'attributs pour les objets de classe `Series`, dont voici quelques exemples :

- `dtype` : retourne le `dtype`, c'est-à-dire le type des données contenues dans la série.
- `iloc` et `loc` : permettent d'accéder aux valeurs de la série, par position ou par étiquette.
- `index` : retourne les index de la série.
- `values` : retourne les valeurs de la série.
- `name` : retourne le nom de la série.
- `size` : retourne le nombre de valeurs contenues dans la série, c'est-à-dire sa taille.

Il est primordial de retenir que, pour chaque classe d'objet, il existe des attributs associés qui permettent de simplifier la manipulation de ces objets, qui sont très utiles.

Exemple pratique

Déterminons la taille de notre série contenant le poids des athlètes.

Code

```
ma_serie_de_poids.size
```

Résultat

```
271116
```

Pour rappel, les attributs sont des variables et s'appellent donc sans parenthèses, contrairement aux méthodes.

b. Les méthodes des objets de classe Series

Pour rappel, en Python, chaque classe a ses propres méthodes, qui peuvent être comparées à des fonctions capables de manipuler cette classe d'objets précisément. La différence entre les méthodes, spécifiques à une classe, et les fonctions, applicables à plusieurs classes, est la manière de les appeler. Une méthode s'appellera de la manière suivante.

```
ma_serie.methode()
```

alors que la fonction s'appellera de la manière suivante :

```
fonction(ma_serie)
```

Il existe énormément de méthodes pour les séries ; toutes sont accessibles dans la documentation liée aux séries : https://pandas.pydata.org/pandas-docs/stable/reference

/api/pandas.Series.html

Il existe donc un ensemble de méthodes pour les objets de classe `Series`, dont voici quelques exemples :

- `describe()` : permet d'afficher un résumé statistique sur les valeurs de la série.
- `value_counts()` : permet de visualiser les valeurs uniques ainsi que leur nombre au sein de la série.
- `replace()` : permet de remplacer une ou plusieurs valeurs par une autre au sein d'une série.
- `set_index()` : permet de redéfinir les index de la série.

Exemple pratique

Imaginons que l'on veuille un résumé statistique de tous les poids de notre série, il faudra utiliser la méthode `describe()`.

La méthode `describe()` est très utilisée pour avoir un premier aperçu de vos données en générant des statistiques descriptives.

Code

```
ma_serie_de_poids.describe()
```

Résultat

```
count   208241.000000
mean        70.701476
std         14.347880
min         25.000000
25%         60.000000
```

```
50%      70.000000
75%      79.000000
max     214.000000
Name: Weight, dtype: float64
```

Cette méthode fournit différentes statistiques. La première, `count`, donne le nombre de valeurs dans la série, sans compter les valeurs manquantes. Nous savons que la taille de notre série est de `271 116` valeurs, et maintenant nous savons que `208 241` valeurs ne sont pas des valeurs manquantes. Ensuite, `70.70` correspond à la valeur moyenne (`mean`) des poids dans notre série, avec une déviation standard (`std`) de `14` (moyenne de 70 kg +/- 14 kg). Le poids minimal dans ce jeu de données est de 25 kg (`min`) et le poids maximal (`max`) de 214 kg. Enfin, nous avons les quartiles, qui permettent de diviser les données en quatre parts égales. L'interprétation est la suivante : 25 % des athlètes font moins de 60 kg, 50 % des athlètes font moins de 70 kg et 75 % des athlètes font moins de 79 kg.

Cette méthode est puissante : vous pouvez constater qu'en une ligne de code, on peut déjà explorer ses données.

6. Ajouter, supprimer et modifier les valeurs d'une série

a. Ajouter des valeurs à une série

Pour ajouter une ou des valeurs à une série, on utilise généralement la méthode `append()`. Cette méthode permet en réalité de concaténer deux ou plusieurs séries ; nous allons voir comment l'utiliser pour ajouter des valeurs à une série, à la volée.

Syntaxe

```
ma_serie.append(pd.Series([valeur], index=["label"]))
```

Dans cette syntaxe, pour ajouter la valeur à la série `ma_serie`, on doit donner un objet de type `Series` à la méthode `append()`, contenant une ou plusieurs valeurs. Ainsi, on peut

découper cette syntaxe en deux parties.

Première partie :

```
pd.Series([valeur], index=["label"])
```

On utilise la fonction `Series` de Pandas, permettant de créer un objet de classe `Series`, à qui on donne une liste de valeurs, puis une liste d'index correspondants. Il est possible de ne pas spécifier l'option `index`, et dans ce cas les index sont créés par Python et correspondent à des nombres incrémentés.

Deuxième partie :

```
ma_serie.append(pd.Series([valeur], index=["label"]))
```

On applique la méthode `append()` à `ma_serie` en lui donnant notre nouvelle série comme option. Ainsi, les deux séries de valeurs sont concaténées.

Comme exemple pratique, ajoutons deux nouveaux athlètes à la série `ma_serie_de_poids` , avec leur poids respectif.

Code

```
ma_serie_de_poids=ma_serie_de_poids.append(pd.Series([90,120],
index=["Claire Muller", "Julien Villeroy"]))
ma_serie_de_poids.loc[["Claire Muller","Julien Villeroy"]]
```

Résultat

```
Claire Muller     90.0
Julien Villeroy   120.0
dtype: float64
```

Ici, la méthode `append()` retourne une nouvelle copie de la série `ma_serie_de_poids` avec les nouvelles valeurs. Étant donné que `append()` crée un

nouvel objet, il ne faut pas oublier de stocker cette nouvelle série dans une variable. Ici, on la stocke dans la même variable que précédemment, nommée `ma_serie_de_poids`. Nous avons ainsi ajouté deux nouvelles valeurs à notre série.

Contrairement à beaucoup de méthodes Pandas, `append()` génère une copie de la série en sortie et n'applique pas directement le traitement sur l'objet original. C'est une sécurité, pour ne pas modifier un objet sans que vous ne vous en rendiez compte. Pandas fait cela pour les méthodes touchant à l'intégrité des données contenues dans un objet, comme le fait la méthode `append()`.

b. Supprimer une valeur d'une série

Pour supprimer une valeur d'une série, on utilisera la méthode `drop()` qui permet de supprimer les valeurs aux étiquettes d'index spécifiées en option.

La syntaxe générale est la suivante :

```
ma_serie.drop(labels=["index1", "index2"], inplace=False)
```

L'option `labels` attend une liste de noms d'index à supprimer.

L'option `inplace` est intéressante : par défaut, elle est à `False`. Si cette option est à `False`, la méthode `drop()` retourne une copie de `ma_serie`, avec la modification effectuée. Si on met l'option à `True`, la méthode `drop()` effectue la modification directement sur l'objet `ma_serie` et ne retourne donc pas de copie. Il aurait été intéressant que cette option soit disponible pour la méthode `append()`, pour ne pas avoir à systématiquement stocker la nouvelle copie dans une variable. Toutefois, cela n'a pas encore été fait par les développeurs Pandas.

Comme exemple pratique, supprimons les deux athlètes que nous avons ajoutés précédemment.

Code

```
ma_serie_de_poids.drop(labels=["Claire Muller","Julien Villeroy"],
inplace=True)
ma_serie_de_poids.loc[["Claire Muller","Julien Villeroy"]]
```

Résultat

Ce code génère une erreur ! En effet, aucun résultat ne peut être généré puisque Claire Muller et Julien Villeroy n'existent plus dans la série.

Sachez que supprimer des données d'une série est peu courant. Il est préférable de filtrer la série et de stocker les valeurs qui nous intéressent dans une nouvelle série, plutôt que d'en modifier une. Pour filtrer la série, vous pouvez utiliser par exemple les expressions booléennes.

c. Modifier les valeurs d'une série

Pour modifier une valeur au sein d'une série, on pourra utiliser les indexeurs `loc` et `iloc` que nous avons vus précédemment lors de l'indexing (accès aux données). Ici, il s'agit de sélectionner la donnée qui nous intéresse via sa position ou son étiquette, puis d'y assigner une nouvelle valeur avec le symbole d'assignation `=`.

La syntaxe générale est la suivante :

```
ma_serie.loc["nom_index"]=nouvelle_valeur
```

ou

```
ma_serie.iloc[position]=nouvelle_valeur
```

Modifions les poids des athlètes Antti Sami Aalto et Andrzej ya dans notre série d'exemple.

Code

```
ma_serie_de_poids.loc[["Antti Sami Aalto"]]=56
ma_serie_de_poids.loc[["Antti Sami Aalto"]]
```

Ce code modifie le poids d'un athlète, Antti Sami Aalto, et lui attribue la valeur `56`.

Résultat

```
Name
Antti Sami Aalto    56.0
Name: Weight, dtype: float64
```

Code

```
ma_serie_de_poids.loc[["Antti Sami Aalto","Andrzej ya"]]=[56,70]
ma_serie_de_poids.loc[["Antti Sami Aalto","Andrzej ya"]]
```

Ce code modifie le poids de deux athlètes. Pour cela, il faut fournir une liste contenant autant de valeurs que de poids d'athlètes à modifier, ici 2. Bien sûr, il faut que la liste de poids qu'on assigne aux athlètes soit de même taille que la liste d'athlètes que l'on donne à `loc`.

Résultat

```
Name
Antti Sami Aalto    56.0
Andrzej ya          70.0
Name: Weight, dtype: float64
```

Si un athlète est présent plusieurs fois dans une série, ce qui est le cas dans ce jeu de données puisqu'un athlète a pu participer à plusieurs JO et/ou plusieurs épreuves, son poids sera modifié à chacune de ses occurrences.

C'est le cas de l'athlète Christine Jacoba Aaftink. Regardons ses occurrences dans le jeu de données avant modification de son poids.

Résultat avant modification

```
Name
Christine Jacoba Aaftink    82.0
Christine Jacoba Aaftink    82.0
Christine Jacoba Aaftink    82.0
Christine Jacoba Aaftink    82.0
Christine Jacoba Aaftink    82.0
Christine Jacoba Aaftink    82.0
Name: Weight, dtype: float64
```

Modifions son poids et assignons la valeur `60` à l'étiquette Christine Jaoba Aaftkink.

Code

```
ma_serie_de_poids.loc[["Christine Jacoba Aaftink"]]=60
ma_serie_de_poids.loc[["Christine Jacoba Aaftink"]]
```

Résultat

```
Name
Christine Jacoba Aaftink    60.0
Christine Jacoba Aaftink    60.0
Christine Jacoba Aaftink    60.0
Christine Jacoba Aaftink    60.0
Christine Jacoba Aaftink    60.0
Christine Jacoba Aaftink    60.0
Name: Weight, dtype: float64
```

Si, pour je ne sais quelle raison, nous voulions modifier une seule occurrence de cette athlète, alors il faudrait utiliser `iloc` plutôt que `loc` et préciser la position à laquelle modifier la valeur. En effet, une position étant unique, une seule valeur serait ainsi modifiée.